

MÔ HÌNH HÓA DỮ LIỆU

B1: Chuẩn bị dataset và tiền xử lý

- Chuẩn bị các thư viện cần thiết và load các dữ liệu vào data frame

```
5 giây # -*- coding: utf-8 -*-  
import pandas as pd  
import re  
from nltk import ngrams  
from gensim.models import Word2Vec  
  
import sys  
  
pd.options.display.max_rows = 9999
```

```
20 giây [3] from google.colab import drive  
drive.mount('/content/drive')  
  
Mounted at /content/drive
```

```
1 giây [4] df = pd.read_csv("/content/drive/MyDrive/truyen_kieu_data.txt", sep="/", names=["row"], encoding="utf8").dropna()  
df.head(10)
```

	row
0	1..Trăm năm trong cõi người ta,
1	2..Chữ tài chữ mệnh khéo là ghét nhau.
2	3..Trải qua một cuộc bể dâu,
3	4..Những điều trông thấy mà đau đớn lòng.
4	5.. Lạ gì bỉ sắc tư phong,
5	6..Trời xanh quen thói má hồng đánh ghen.
6	7..Cảo thơm lần giở trước đèn,
7	8..Phong tình có lục còn truyền sử xanh.
8	9,,Rằng năm Gia Tĩnh triều Minh,
9	10.. Bốn phương phẳng lặng, hai kinh vững vàng.

- Xử lý từng dòng dữ liệu (xóa số dòng, bỏ các dấu dư thừa)

▼ Xử lý từng dòng thơ

✓
0
giây

```
def transform_row(row):  
    #row = row.encode("utf-8")  
    # Xóa số dòng ở đầu câu  
    row = re.sub(r"^[0-9\.\.]+", "", row)  
  
    # Xóa dấu chấm, phẩy, hỏi ở cuối câu  
    row = re.sub(r"[\.,\?]+$", "", row)  
  
    # Xóa tất cả dấu chấm, phẩy, chấm phẩy, chấm thang, ... trong câu  
    row = row.replace(",", " ").replace(".", " ") \\\n        .replace(";", " ").replace("'", " ") \\\n        .replace(":", " ").replace(":", " ") \\\n        .replace("'", " ").replace("'", " ") \\\n        .replace("!", " ").replace("?", " ")  
  
    row = row.strip()  
    return row  
  
df["row"] = df.row.apply(transform_row)  
df.head(10)
```



row



0	Trăm năm trong cõi người ta
1	Chữ tài chữ mệnh khéo là ghét nhau
2	Trải qua một cuộc bể dâu
3	Những điều trông thấy mà đau đớn lòng
4	Lạ gì bỉ sắc tư phong
5	Trời xanh quen thói má hồng đánh ghen
6	Cảo thơm lần giở trước đèn
7	Phong tình có lục còn truyền sử xanh
8	Rằng năm Gia Tĩnh triều Minh
9	Bốn phương phẳng lặng hai kinh vững vàng

- Tách từ bằng cách sử dụng ngram

```
[6] %%timeit
def kieu_ngram(string, n=1):
    gram_str = list(ngrams(string.split(), n))
    return [ " ".join(gram).lower() for gram in gram_str ]

df["1gram"] = df.row.apply(lambda t: kieu_ngram(t, 1))
df["2gram"] = df.row.apply(lambda t: kieu_ngram(t, 2))

56.8 ms ± 11 ms per loop (mean ± std. dev. of 7 runs, 10 loops each)
```

```
df.head(10)
```

	row	1gram	2gram
0	Trăm năm trong cõi người ta	[trăm, năm, trong, cõi, người, ta]	[trăm năm, năm trong, trong cõi, cõi người, ng...
1	Chữ tài chữ mệnh khéo là ghét nhau	[chữ, tài, chữ, mệnh, khéo, là, ghét, nhau]	[chữ tài, tài chữ, chữ mệnh, mệnh khéo, khéo l...
2	Trải qua một cuộc bể dâu	[trải, qua, một, cuộc, bể, dâu]	[trải qua, qua một, một cuộc, cuộc bể, bể dâu]
3	Những điều trông thấy mà đau đớn lòng	[những, điều, trông, thấy, mà, đau, đớn, lòng]	[những điều, điều trông, trông thấy, thấy mà, ...]
4	Là gì bỉ sắc tư phong	[là, gì, bỉ, sắc, tư, phong]	[là gì, gì bỉ, bỉ sắc, sắc tư, tư phong]
5	Trời xanh quen thói má hồng đánh ghen	[trời, xanh, quen, thói, má, hồng, đánh, ghen]	[trời xanh, xanh quen, quen thói, thói má, má ...]
6	Cảo thơm lần giở trước đèn	[cảo, thơm, lần, giở, trước, đèn]	[cảo thơm, thơm lần, lần giở, giở trước, trước...
7	Phong tình có lục cón truyền sử xanh	[phong, tình, có, lục, cón, truyền, sử, xanh]	[phong tình, tình có, có lục, lục cón, cón tru...
8	Rằng năm Gia Tĩnh triều Minh	[rằng, năm, gia, tĩnh, triều, minh]	[rằng năm, năm gia, gia tĩnh, tĩnh triều, triề...
9	Bốn phương phẳng lặng hai kinh vững vàng	[bốn, phương, phẳng, lặng, hai, kinh, vững, vàng]	[bốn phương, phương phẳng, phẳng lặng, lặng ha...

```
df["context"] = df["1gram"] + df["2gram"]
df.head(10)
```

	row	1gram	2gram	context
0	Trăm năm trong cõi người ta	[trăm, năm, trong, cõi, người, ta]	[trăm năm, năm trong, trong cõi, cõi người, ng...	[trăm, năm, trong, cõi, người, ta, trăm năm, n...
1	Chữ tài chữ mệnh khéo là ghét nhau	[chữ, tài, chữ, mệnh, khéo, là, ghét, nhau]	[chữ tài, tài chữ, chữ mệnh, mệnh khéo, khéo l...	[chữ, tài, chữ, mệnh, khéo, là, ghét, nhau, ch...
2	Trải qua một cuộc bể dâu	[trải, qua, một, cuộc, bể, dâu]	[trải qua, qua một, một cuộc, cuộc bể, bể dâu]	[trải, qua, một, cuộc, bể, dâu, trải qua, qua ...]
3	Những điều trông thấy mà đau đớn lòng	[những, điều, trông, thấy, mà, đau, đớn, lòng]	[những điều, điều trông, trông thấy, thấy mà, ...]	[những, điều, trông, thấy, mà, đau, đớn, lòng...
4	Là gì bỉ sắc tư phong	[là, gì, bỉ, sắc, tư, phong]	[là gì, gì bỉ, bỉ sắc, sắc tư, tư phong]	[là, gì, bỉ, sắc, tư, phong, là gì, gì bỉ, bí ...]
5	Trời xanh quen thói má hồng đánh ghen	[trời, xanh, quen, thói, má, hồng, đánh, ghen]	[trời xanh, xanh quen, quen thói, thói má, má ...]	[trời, xanh, quen, thói, má, hồng, đánh, ghen....]
6	Cảo thơm lần giở trước đèn	[cảo, thơm, lần, giở, trước, đèn]	[cảo thơm, thơm lần, lần giở, giở trước, trước...	[cảo, thơm, lần, giở, trước, đèn, cảo thơm, th...
7	Phong tình có lục cón truyền sử xanh	[phong, tình, có, lục, cón, truyền, sử, xanh]	[phong tình, tình có, có lục, lục cón, cón tru...	[phong, tình, có, lục, cón, truyền, sử, xanh, ...]
8	Rằng năm Gia Tĩnh triều Minh	[rằng, năm, gia, tĩnh, triều, minh]	[rằng năm, năm gia, gia tĩnh, tĩnh triều, triề...	[rằng, năm, gia, tĩnh, triều, minh, rằng năm, ...]
9	Bốn phương phẳng lặng hai kinh vững vàng	[bốn, phương, phẳng, lặng, hai, kinh, vững, vàng]	[bốn phương, phương phẳng, phẳng lặng, lặng ha...	[bốn, phương, phẳng, lặng, hai, kinh, vững, và...

B2: Truy vấn và tìm những từ gần nhau

- Chọn từ “Tài” thuộc mô hình xây dựng

```
model.wv.similar_by_word("tài")

[('đàn', 0.9996833801269531),
 ('dễ', 0.9996511936187744),
 ('kinh', 0.9996483325958252),
 ('bình', 0.999640703201294),
 ('khôn', 0.9996395111083984),
 ('quá', 0.9996377229690552),
 ('thay', 0.9996342658996582),
 ('chăng', 0.999622642993927),
 ('kiểu', 0.9996213912963867),
 ('bể', 0.9996187090873718)]
```

- Qua dòng code trên ta thấy được những từ thường đứng gần chữ *tài* trong tác phẩm Truyện Kiều của Nguyễn Du như là chữ *đàn*, *dễ*, *kinh*, *bình*... Và chúng ta không thấy sự xuất hiện của từ *tai* trong danh sách trên. Sở dĩ nhắc đến chữ *tai* ở đây vì Nguyễn Du đã có 1 câu thơ rất nổi tiếng “Chữ *tài* liền với chữ *tai* một vần” câu thơ thể hiện *tài* mang lại cho ta rất nhiều danh vọng, tiền bạc, nhưng nếu dùng những *tài* năng đó vào những điều xấu thì có *tai* cũng trở nên vô nghĩa rồi mang lại những “*tai*” cho mình. Vì đoạn code này chỉ truy vấn những từ thường đi gần với chữ *tài* thôi (Ví dụ như *tài* đánh *đàn*) thường đi với nhau nên nó truy vấn ra được còn nếu nghĩ theo hướng giống như câu trên của Nguyễn Du thì không thể được.
- **Chọn từ không thuộc trong mô hình**
- Vì số lượng từ được dùng trong tác phẩm Truyện Kiều rất nhiều nên khó để mà có thể chọn bừa 1 từ để truy vấn nên em đã quyết định chọn từ “*sỹ*” bởi 1 phần nó nằm trong tên em 1 phần e cũng thấy nó lạ ít khi được sử dụng trong thơ ca.

```
model.wv.similar_by_word("sỹ")

-----
KeyError                                Traceback (most recent call last)
<ipython-input-27-1dce8f9b2cd0> in <module>
----> 1 model.wv.similar_by_word("sỹ")

----- 2 frames -----
/usr/local/lib/python3.8/dist-packages/gensim/models/keyedvectors.py in word_vec(self, word, use_norm)
    450         return result
    451     else:
--> 452         raise KeyError("word '%s' not in vocabulary" % word)
    453
    454     def get_vector(self, word):

KeyError: "word 'sỹ' not in vocabulary"

SEARCH STACK OVERFLOW
```

- Và như đã dự đoán không thể truy vấn từ “sỹ” trong tác phẩm trên.

KeyError: "word 'sỹ' not in vocabulary"

B3: PCA và visualization

▼ PCA và plot 2d

```
✓ [21] from sklearn.decomposition import PCA
0      import matplotlib.pyplot as plt
iây
```

```
words_np = []
words_label = []
for word in model.wv.vocab.keys():
    words_np.append(model.wv[word])
    words_label.append(word)
```

```
pca = PCA(n_components=2)
pca.fit(words_np)
reduced = pca.transform(words_np)
```

```
✓ %matplotlib inline
3      plt.rcParams["figure.figsize"] = (20,30)
iây      for index,vec in enumerate(reduced):
          if index <100:
              x,y=vec[0],vec[1]
              plt.scatter(x,y)
              plt.annotate(words_label[index],xy=(x,y))
plt.show()
```


